

FPT UNIVERSITY

GPT-4O-MINI



Presented by:
Team 4

EVO SUITE

Class: SE1944 - SUMMER 2026

GPT-4o-mini versus EvoSuite: A Mutation Score-Based
Evaluation of Zero-Shot Unit Test Generation on
CLASSES2TEST

TEAM 4

MEMBERS & CONTRIBUTIONS

- PL (Project Lead): Trần Bích Trâm - SE190313
- DG (Data & Growth Truth): Trần Minh Quý - SE196687
- LR (LLM Runner): Lê Trần Anh Khoa - SE192585
- MS (Metric/Stat): Trương Đan Huy - SE196508
- RW (Report Writer): Vương Quốc Khánh - SE196464



CONTEXT

Problem & Motivation	01.
Evidence from Related Work	02.
Research GAP	03.
Research Questions (RQ1 & RQ2)	04.
Research Questions (RQ3 & RQ4)	05.
Hypotheses and Thresholds	06
Experiment Pipeline	07.

Statistical Plan	08.
Threats and Mitigation	09.
Timeline and Roles	10.
Expected Contribution	11.

PROBLEM & MOTIVATION

Các nghiên cứu về sinh Unit Test bằng LLM thường đánh giá bằng:

- Line Coverage
- Branch Coverage
- Build Success

Tuy nhiên,

Coverage cao không đồng nghĩa với khả năng phát hiện lỗi tốt.

have shifted attention toward LLM-based test generation. However, code coverage metrics—such as line and branch coverage—remain overly emphasized in reported research, despite being weak indicators of a test suite’s fault-detection capability. In contrast, *mutation score* offers a more reliable and stringent measure, as demonstrated in our findings where some test suites achieve 100% coverage but only 4% mutation score. Although a few studies consider mutation score, the effectiveness of LLMs in killing mutants remains underexplored.

In this paper, we propose MUTGEN, a mutation-guided, LLM-based test generation approach that incorporates mutation feedback directly into the prompt. Evaluated on 204 subjects from two benchmarks, MUTGEN significantly outperforms both EvoSuite and vanilla prompt-based strategies in terms of mutation score. Furthermore, MUTGEN introduces an iterative generation mechanism that pushes the limits of LLMs in killing

Motivation

Nghiên cứu ID 55 (MutGen - 2026) cho thấy:

100% Coverage

≠

4% Mutation Score

Test có thể chạy qua toàn bộ mã nguồn nhưng vẫn bỏ sót phần lớn lỗi tiềm ẩn.

EVIDENCE FROM RELATED WORK

FRAGMENTED METRICS

Hệ thống chỉ số đánh giá thiếu tính đồng nhất.

Hậu quả: Gây khó khăn khi đối chiếu chéo giữa các nghiên cứu.

MUTATION AS SECONDARY

Mutation testing chưa được coi là tiêu chuẩn đánh giá cốt lõi.

Hậu quả: Đánh giá chất lượng test suite bị hạn chế, thiếu chiều sâu.

SYNTHETIC DATASETS

Lệ thuộc nặng nề vào các tập dữ liệu nhân tạo (Synthetic datasets).

Hậu quả: Kết quả mang tính lý thuyết, thiếu độ tin cậy trong môi trường thực tế.

RESEARCH GAP - M

PRIMARY MUTATION

Mutation testing làm thước đo đánh giá cốt lõi

REAL-WORLD JAVA

Tập dữ liệu từ các dự án Java thực tế

EVOSUITE BASELINE

Sử dụng công cụ tạo test tự động tiêu chuẩn làm hệ quy chiếu so sánh

GAP (Khoảng trống):

Các nghiên cứu hiện có mới chỉ giải quyết riêng lẻ từng yếu tố:

- Dùng mutation score nhưng trên benchmark nhân tạo.
- Dùng real-world Java nhưng không so với baseline tiêu chuẩn.
- So sánh với EvoSuite nhưng không dùng mutation làm metric chính.

Chưa có công trình nào hội tụ đủ cả ba yếu tố trên cùng một thiết kế thí nghiệm.

HỆ LUY: Thiếu một đánh giá đồng bộ khiến kết luận về hiệu năng của LLM trong sinh test trở nên rời rạc, thiếu cơ sở so sánh công bằng.

ĐÓNG GÓP CỦA NHÓM: Lần đầu tiên khóa điểm giao thoa (Intersection) này bằng thiết kế thí nghiệm trên 30 class từ 10 dự án Java thực tế (CLASSES2TEST), so sánh GPT-4o-mini với EvoSuite lấy Mutation Score làm thước đo chính.

RESEARCH QUESTIONS (RQ1 & RQ2)

RQ1 - MUTATION QUALITY

GPT-4o-mini zero-shot có đạt **median mutation score $\geq 44.5\%$** không?

Thước đo: Mutation Score (PIT)

Ngưỡng chốt: 44.5% (tính từ Pilot Study)

Phương pháp: Kiểm định Wilcoxon one-sample so với ngưỡng 44.5% ($p < 0.05$)

RQ2 - COVERAGE FLOOR

GPT-4o-mini zero-shot có đạt **median branch coverage $\geq 41.9\%$** không?

Thước đo: Branch Coverage (JaCoCo)

Ngưỡng chốt: 41.9% (tính từ Pilot Study)

Phương pháp: Kiểm định Wilcoxon one-sample so với ngưỡng 41.9% ($p < 0.05$)

model	prompt name	branch coverage%	line coverage%	method coverage%	mutation score%	AR	EH	MG	EA
gpt-4o-mini	zero-shot	41.9% ↓	64.8% ↓	77.2% ↑	44.5% ↑	1.28	0.79	0.19	2.11
	few-shot	62.1% ↑	71.3% ↑	81.1% ↑	61.0% ↑	1.01	0.36	0.08	1.54
gemini-1.5-pro	zero-shot	22.6% ↓	55.4% ↓	62.8% ↓	30.1% ↓	1.67	0.42	0.09	2.85
	few-shot	44.6% ↓	89.8% ↑	92.9% ↑	72.0% ↑	1.96	0.41	0.03	2.92
llama3.1:70b	zero-shot	71.2% ↑	80.3% ↑	84.9% ↑	32.0% ↓	1.77	0.27	0.07	0.51
	few-shot	79.8% ↑	85.6% ↑	90.3% ↑	89.2% ↑	0.55	0.30	0.05	1.31
human	-	48.7%	73.2%	74.0%	40.4%	2.18	0.69	0.10	1.68

RESEARCH QUESTIONS (RQ3 & RQ4)

RQ3 - PRACTICAL USABILITY

GPT-4o-mini zero-shot có đạt tỷ lệ **Build Success** $\geq 28.6\%$ không?

Thước đo: Build Success Rate (Maven Surefire)

Ngưỡng chốt: 28.6% (từ Pilot Study)

Phương pháp: Kiểm định Binomial one-sample so với ngưỡng 28.6% ($p < 0.05$)

RQ4 - COMPARATIVE BASELINE

Mutation score của **GPT-4o-mini** có cạnh tranh được với **EvoSuite (Baseline)** không?

Thước đo: Mutation Score (PIT)

Baseline: EvoSuite (chạy đúng 60 giây/class trên cùng 30 class)

Phương pháp: Kiểm định Wilcoxon Signed-Rank (so sánh cặp 2 mẫu phụ thuộc, $p < 0.05$)

HYPOTHESES & THRESHOLDS

RQ1 - MUTATION QUALITY

Metric: Mutation (PIT)

Threshold: $\geq 44.5\%$

Source: Table IV, ID 9

H_0 : $GPT < 44.5\%$

H_1 : $GPT \geq 44.5\%$

Test: Wilcoxon ($\alpha=0.05$)

RQ2 - COVERAGE FLOOR

Metric: Branch (JaCoCo)

Threshold: $\geq 41.9\%$

Source: Table IV, ID 9

H_0 : $GPT < 41.9\%$

H_1 : $GPT \geq 41.9\%$

Test: Wilcoxon ($\alpha=0.05$)

RQ3 - PRACTICAL USABILITY

Metric: Build Success (Surefire)

Threshold: $\geq 28.6\%$

Source: Table V, ID 9

H_0 : $GPT < 28.6\%$

H_1 : $GPT \geq 28.6\%$

Test: Binomial ($\alpha=0.05$)

RQ4 - COMPARATIVE BASELINE

Metric: Mutation Score (PIT)

Margin: Delta > -5 percentage points


Source: Pilot Study, practical significance

H_0 : $GPT \leq \text{EvoSuite} - 5\%$

H_1 : $GPT > \text{EvoSuite} - 5\%$

Test: Wilcoxon Signed-Rank (one-sided, $\alpha=0.05$)

EXPERIMENT PIPELINE



STATISTICAL PLAN

RQ1 - MUTATION SCORE

- Metric: Trung vị mutation score
- Kiểm định: One-sample Wilcoxon
- Lý do: Dữ liệu dạng phần trăm, không giả định phân phối chuẩn

RQ2 - BRANCH COVERAGE

- Metric: Trung vị branch coverage
- Kiểm định: One-sample Wilcoxon
- Lý do: Điểm coverage được đo theo từng class

RQ3 - BUILD SUCCESS

- Metric: Tỷ lệ build thành công
- Kiểm định: Binomial exact test
- Lý do: Kết quả dạng nhị phân: thành công / thất bại

RQ4 - GPT VS EVOSUITE

- Metric: Phân phối mutation score
- Kiểm định: Mann-Whitney U
- Effect size: A12
- Mục đích: So sánh mức độ khác biệt thực tế giữa GPT-4o-mini và EvoSuite

Silent Model Drift

- Nguy cơ: Hành vi của LLM có thể thay đổi theo thời gian
- Giảm thiểu: Cố định đúng phiên bản model
- Ghi log timestamp, cấu hình request và raw response

Small Sample Size

- Nguy cơ: Độ mạnh thống kê thấp
- Giảm thiểu: Chạy pilot gate trước
- Tăng sample từ 30 lên 40 nếu số class phân tích được < 24

THREATS AND MITIGATION


Build-fail Bias


- Nguy cơ: Kết quả có thể bị “đẹp giả tạo” nếu bỏ qua các test bị lỗi
- Giảm thiểu: Test fail build/run = 0.0 điểm
- Giữ nguyên toàn bộ mẫu trong mẫu số

Limited Generalizability

- Nguy cơ: Kết quả có thể không áp dụng cho mọi ngôn ngữ hoặc project
- Giảm thiểu: Giới hạn phạm vi kết luận
- Chỉ claim trong phạm vi Java class-level unit test generation trên CLASSES2TEST


TIMELINE & ROLES






EXPECTED CONTRIBUTION

Standardized Benchmark (Thước đo chuẩn hóa), First Comparison (So sánh đầu tiên), Value of Negative Result (Giá trị của kết quả âm).



FPT UNIVERSITY

THANK



Presented by:
Team 4

Presentation

GPT-4o-mini versus EvoSuite: A Mutation
Score-Based Evaluation of Zero-Shot Unit Test
Generation on CLASSES2TEST

YOU